



Análise Textual por Época

Grupo 10 · Prof. John Lenon e Glauco Vitor

EDA2 — 2026.1 · UnB Campus Gama (FCTE)

Descrição do Problema

Este projeto tem como objetivo analisar comparativamente textos de diferentes épocas, identificando as transformações ocorridas em seu conteúdo e formato com o decorrer do tempo.




Modelagem do grafo

- **Vértices:** Palavras nos textos.
- **Arestas:** Coocorrência de palavras no mesmo texto.
- **Peso:** Quantidade de textos onde há coocorrência.

Os grafos foram desenvolvidos em formato de **Listas de Adjacência** (dicionários de dicionários).

- Facilidade na leitura dos dados;
- Melhor aplicação para os algoritmos selecionados (busca de vizinhos).



Descrição da solução

Como nosso objetivo é comparar escritas de diferentes épocas, o ideal é a utilização de grafos.

Para solucionar esse problema, utilizou-se a biblioteca spaCy na filtragem dos dados, além de algoritmos de exibição em árvore para otimizar a análise.

- **Tema Escolhido:** Economia;
- **Tipo de Dados:** Fictícios;
- **Algoritmos aplicados:** BFS e Kruskal;
- **Tratamento de Dados:** spaCy.

Implementação

- **Plataforma de Desenvolvimento:** Python
- **Modulos Utilizados:** spaCy
 - **Pipeline:** pt_core_news_sm

Arquivos do Programa

main.py

Carrega os dados e chama as funções dos outros arquivos.

grafos.py

Gera as principais estruturas de dados, como grafos e listas.

algoritmos.py

Possui todas funções relacionadas aos algoritmos.

processamento_d


e_dados.py

Aplica o filtro do spaCy e salva dados.

Implementação

- **Plataforma de Desenvolvimento:** Python
- **Modulos Utilizados:** spaCy
 - **Pipeline:** pt_core_news_sm

Fluxo do Programa



Entrada de Dados

Os dados utilizados devem estar armazenados na pasta **data/texts/** em formato **txt** em relação ao arquivo **main.py**, cada dentro de sua respectiva pasta.

```
src/
├── main.py
│   └── data/
│       └── text/
│           ├── epoca1/
│           │   └── texto1.txt
│           ├── epoca2/
│           │   └── ...
│           └── ...
```

Em nossos testes, tínhamos vinte textos pequenos das seguintes épocas:

- **2020**
- **2010**
- **2000**
- **1990**

Análise dos resultados

Número de Vértices:

- **2020:** 527
- **2010:** 487
- **2000:** 449
- **1990:** 542

Os dados geralmente apresentam uma ligação um pouco mais forte com épocas adjacentes.

Época	2020	2010	2000	1990
2020	527	212	191	202
2010	212	487	201	175
2000	191	201	449	168
1990	202	175	168	542

Tabela de Coocorrência

Aplicação do Bfs

Implementação:

- Recebe o grafo de cada época;
- Define o termo inicial como nó raiz;
- Explora os nós vizinhos por níveis;
- Calcula as distâncias mínimas até os demais termos;
- Gera a Árvore BFS de cada época;
- Salva os resultados em
/data/processed/bfs_[época].json

Resultados da Arvore Geradora BFS

Árvore BFS da palavra **economia**:

- **1990 - altura: 2 Níveis**
- **2000 - altura: 2 Níveis**
- **2010 - altura: 2 Níveis**
- **2020 - altura: 3 Níveis**

A altura da árvore BFS passou de dois níveis (1990–2010) para três níveis em 2020, mostrando um aumento na complexidade das relações econômicas.

Enquanto nos anos anteriores os impactos eram mais diretos, em 2020 a pandemia gerou mais ramificações e consequências, exigindo um nível adicional para representar seus efeitos.

Analise de resultados (BFS)

A Busca em Largura (BFS) foi utilizada para percorrer o grafo a partir do vértice "economia", organizando as palavras relacionadas em níveis de distância. Com base nos termos encontrados em cada nível, foi realizada uma análise da percepção econômica em diferentes décadas.

Analise de Resultados (BFS)

1990:

- **Termos próximos:** "choque", "confisco" e "hiperinflação".
- **Termos secundários:** "pânico", "demissão" e "empobrecimento".
- **Análise:** Os resultados indicam uma percepção associada à crise econômica, marcada por instabilidade e perda de poder aquisitivo.

2000:

- **Termos próximos:** "estabilizar" e "previsibilidade".
- **Termos secundários:** "crescimento", "expansão", "déficit" e "desemprego".
- **Análise:** Os termos sugerem um período de reorganização econômica, combinando sinais de recuperação com desafios ainda presentes.

Analise de Resultados (BFS)

2010:

- **Termos próximos:** "crescimento", "vigoroso" e "superávit".
- **Termos secundários:** "boom", "pujante" e "recorde".
- **Análise:** O período apresenta a percepção mais positiva da série, associada à expansão econômica e ao aumento da confiança.

2020:

- **Termos próximos:** "retração" e "paralisação".
- **Termos secundários:** "asfixiar" e "socorrer".
- **Análise:** Os resultados refletem os impactos da pandemia, com forte associação a dificuldades econômicas e medidas emergenciais de saúde e segurança.

Aplicação do Kruskal

Implementação:

- Recebe os grafos de cada época;
- Ordena todas as arestas por peso de forma decrescente
- Usa Union-Find para selecionar arestas sem formar ciclos;
- Gera a Árvore Geradora Máxima de cada época;
- Salva os resultados em **`/data/processed/kruskal_[época].json`**

Resultados do Kruskal

Árvores Geradoras Máximas por Época

```
Aplicando algoritmo de Kruskal por Época...  
Kruskal 2020: 526 arestas, 1 componente(s), peso total 1220  
Kruskal 1990: 541 arestas, 1 componente(s), peso total 1120  
Kruskal 2010: 486 arestas, 1 componente(s), peso total 1080  
Kruskal 2000: 448 arestas, 1 componente(s), peso total 939
```

Todos os grafos formaram 1 componente conectado.

Análise do Kruskal

Conclusões que podemos ver pelos testes:

- Todos os grafos são conexos devido ao número de componentes.
- Os peso médio indica que as conexões do grafo de 2020 são mais “valiosas”, enquanto que 1990 possui um grafo mais espalhado.
- O crescimento do peso médio com o passar das décadas indica aumento na ligação do conteúdo.

Peso médio dos componentes:

- **2020:** $1222/526 = 2,32$
- **2010:** $1080/486 = 2,22$
- **2000:** $939/448 = 2,10$
- **1990:** $1120/541 = 2,07$

Conclusões


Os grupos apresentaram resultados semelhantes, porém progressivos ao longo das épocas.

A temática econômica influenciou os resultados devido ao uso recorrente de termos predefinidos na área e à clara evolução pela qual o setor passou com o decorrer dos anos. Apesar disso, os assuntos representados nos grafos mostram-se variados.



Uso de LLMs

- **Geração de Dados Fictícios:** Uso do Google Gemini para criar artigos de economia brasileira (1990-2020).
 - **Controle de Viés:** Os títulos foram omitidos para evitar algum tipo de viés nos dados.
 - **Consistência Cronológica:** Prompts demandaram preservação do vocabulário, a gramática e o contexto socioeconômico de cada década.
- **Auxílio no Código:** Foi utilizado LLMs como forma de auxílio na construção de alguns código e algoritmos.
- **Ferramenta de Pesquisa:** Tirar dúvidas sobre o conteúdo sendo aplicado.



OBRIGADO!